AgentCache

让热点前缀抵抗一次性请求冲刷

vLLM 原生有界 Two-Queue 缓存策略
求职展示 / 开源配套说明

问题不是缓存更多答案，而是让已经计算过、可能再次复用的上下文 KV，在有限空间中更合理地保留。

交付重点	工程边界
原生配置、块生命周期、指标、测试和演示	单卡 V1 / 纯文本 / APC / 固定版本
48 项原生测试；15,000 状态比较	历史证据，本轮未重跑 GPU
7B 扫描后热点命中 99.48%	只限单次合成扫描，不外推生产

维护仓库：github.com/lingjiekong04/agentcache-vllm
公开候选整理日期：2026-10-24
代码与文档有 AI 辅助；上游能力、新增工作和个人验收需分开说明。

01 / 问题与目标

Agent 多轮调用经常共享长系统上下文。APC 可以跨请求复用相同 token 前缀的完整 KV 块，但一次性长请求也会进入缓存，并可能把反复返回的热点冲走。

从 KV Cache 到 APC

KV Cache 减少同次生成对历史 K/V 的重复计算；APC 复用跨请求前缀，不返回旧答案，也不判断语义相似。新 token 仍需计算并访问历史 KV。

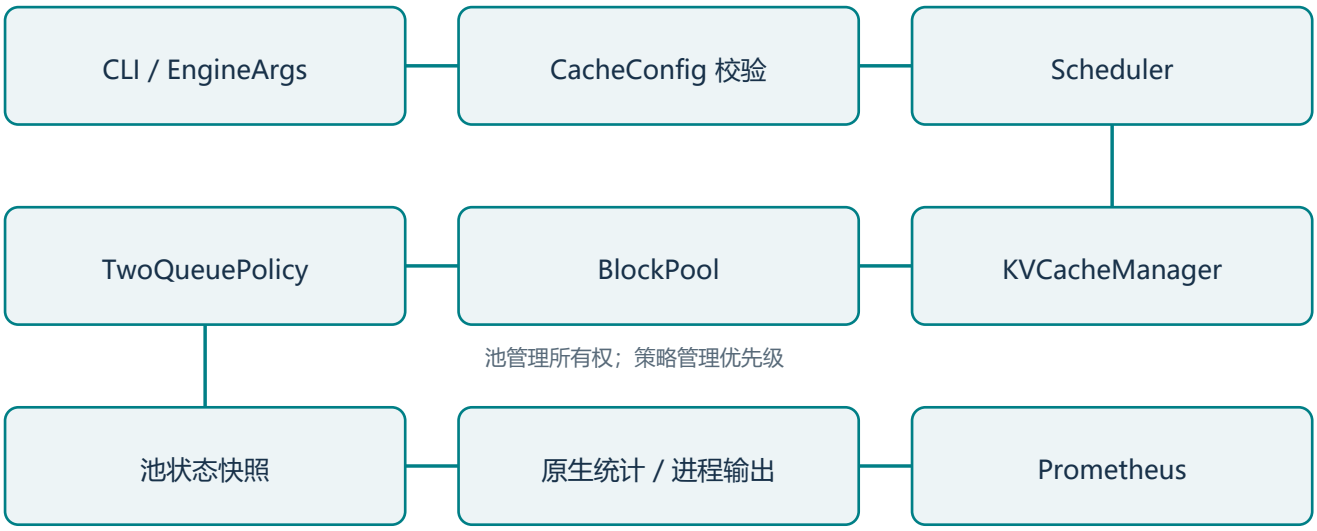
维度	实际含义
空闲	普通块引用数为 0，不代表显存清零
有缓存	完整块哈希可被兼容前缀命中
受保护	策略赋予优先级，可含活动块
正在使用	引用数大于 0，不得作为空闲分配候选

设计目标

不增加物理缓存池容量，不重写 Attention kernel。只改变空闲块选择和有界保护，使扫描压力下仍可留下热点，同时保持原生引用和哈希索引安全。

非目标：完整 ARC、ghost history、自适应保护比例、多 GPU、完整 Agent 工具执行平台和生产高可用。

02 / 原生架构与运行流程



配置沿真实调用链进入池，统计沿现有 EngineCore 输出链返回前端。不是实验启动器临时替换类。

位置	职责
config.py / arg_utils.py	声明参数、默认值及不支持组合拒绝
scheduler.py / kv_cache_manager.py	调度、前缀命中与块需求
block_pool.py	引用、哈希、重复副本索引、分配/释放/reset
gpu_eviction_policy.py	冷热空闲、有序保护、降级和热区回退
stats.py / loggers.py	快照与累计计数求增量

运行身份

实际 EngineCore 写出 AGENTCACHE_NATIVE_ENGINE，记录队列类型、配置和 10 个核心源文件哈希。命令行声明本身不足以证明使用了工程代码。

03 / Two-Queue 的真实生命周期

核心原则：保护是优先级，引用是安全约束。

操作	引用/队列变化	安全含义
两个请求共享 A	1 -> 2 -> 1 -> 0	最后一个引用释放才可入队
查找再 touch	查找不加引用；touch 先取引用再晋升	不能把查到等同于占有
保护额度超限	最旧保护失效，引用数不变	活动块降级后仍不可分配
冷区耗尽	从热区空闲队列回退	保护不是永久 pin
重用同哈希副本	仅删除该 block_id 的旧索引	其它副本保持有效
reset	活动引用时拒绝；成功清哈希/保护	累计计数不归零

有界额度

扣除 null block 后取比例：256 总块、ratio=0.5 时额度 127；1024 总块时额度 511。保护集合不等于热区空闲队列。

复杂度

单块队列/字典操作和快照不扫描全池；请求处理 k 个块仍为 O(k)。reset 与调试遍历允许扫描。默认 LRU 没有 Two-Queue 表维护，但观测分支并非绝对零开销。

04 / 配置、可观测性与正确性

配置	要求
gpu_eviction_policy	lru（默认）或 two_queue
gpu_cache_protected_ratio	默认 0.5；Two-Queue 要求有限且在 (0,1]
首版支持	V1 / CUDA / TP、PP、DP 均为 1 / APC 开启
缓存与模型	单非 MLA FullAttention 组、纯文本生成

不支持配置明确拒绝

滑窗、混合缓存组、LoRA、prompt adapter、推测解码、KV transfer 等不静默退回其它策略。

指标

Gauge：冷区/热区空闲、保护块数与额度。Counter：晋升、配额降级、冷/热缓存淘汰。沿用 model_name、engine 标签，不增加会话或请求 ID。

池累计值 5 -> 5 -> 8，应导出增量 5 -> 0 -> 3，不能每次把绝对值重复累加。首次调度快照之前 Gauge 是零占位；初始额度应看 EngineCore 身份。

取消只释放本请求引用；抢占释放所有权后请求仍可能等待恢复。测试分别覆盖这些阶段，而不是把取消与请求正常结束混为一谈。

05 / 固定输入与实验设置

场景	请求数/单策略	目的
多会话多轮	17	共享长上下文的固定轨迹
扫描后返回	75	热点、一次性冷扫描、返回探测
工作集切换	30	新热点接纳与旧热点降级
纯冷负对照	45	无复用时的维护成本

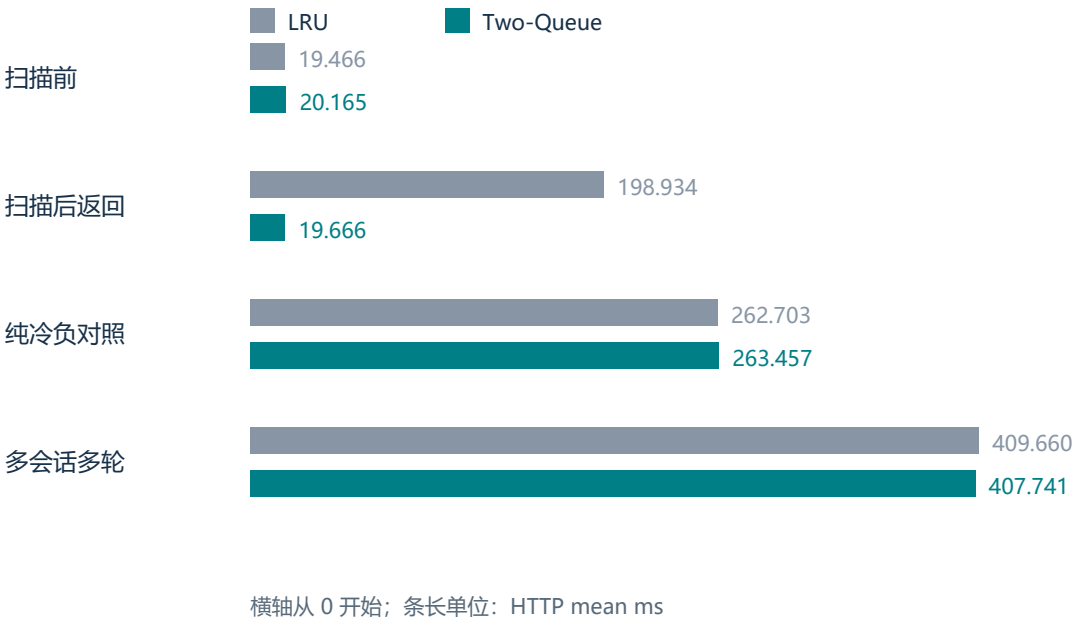
每场景包含 5 次引擎预热；单模型单策略 167 请求，两个模型两策略合计 668 请求、334 对输出。工具结果是预录制文本，不执行外部命令。

设置	0.5B 快速回归	7B 最终演示
上下文 / 总块数	2048 / 256	8192 / 1024
数据类型 / block size	BF16 / 16	BF16 / 16
保护比例 / seed	0.5 / 0	0.5 / 0
max_num_seqs	串行 1；生命周期 4	串行 1；生命周期 4

硬件与控制

A100-SXM4-80GB，驱动 550.54.14；每配对同硬件和输入、全新服务。7B 生命周期另属功能验收批次，不与串行时延混算。完整请求日志关闭，访问和周期日志保留。

06 / 结果：热点保留与负对照



图：7B 历史单次配对，阶段 mean HTTP 完整响应时延。原始值来自 evidence/results.json；不是 TTFT 或 GPU kernel 时间。

7B 扫描后

5 次返回探测共 960 查询块；LRU 命中 0，Two-Queue 命中 955（99.48%）。HTTP mean 198.934 -> 19.666 ms，约下降 90.1%，只描述这个构造和阶段。

0.5B 负结果 mean ms	LRU	Two-Queue
多会话多轮	137.430	152.717
切换后的新热点	8.225	15.897
纯冷请求	12.627	14.936

负结果必须保留。两版冷扫描均无命中却有时延差，不能把整段差异归因于策略。单次配对与同服务窗口不构成统计显著性或生产整体提速证明。

07 / 验证分层与证据范围

验证层次	实际证据	不能替代
CPU 合约	7 项、15,000 状态；LRU 对官方、Two-Queue 对冻结 v2	完整 GPU 推理
原生 pytest	两份 prefix/scheduler 文件 48 项，含新增 9 项	上游全套和所有并发正确性
串行服务	16 次新服务；668 请求、334 对输出一致	所有输入的模型质量
生命周期	4 次服务；84 完整响应、4 次断连；每次 2 抢占	全部竞态和内部 KV 数值
本次公版检查	重建、工具测试、来源/哈希和 PDF 检查	新一轮原生或 GPU 成绩

历史证据独立审核

本次对已有原包重新离线审核，不执行包内代码。输入、逐请求缓存增量、原比较结果、源码和日志身份经复算。公开只保留聚合字段，原始日志/响应不附带。

来源哈希

原证据 SHA256：
4f74650c8659bb41914c65a734ec3468b6608b2a7f7f3318374b5d939672276e

没有私有原包的读者不能独立重审每个请求。新的公版完整性清单也不能冒充原验收身份。

08 / 真实迭代与工作归属

组件/记录	改变与解决问题	最终状态
实验 v1 -> 冻结 v2	固化有界保护与生命周期参考	仅用于差分来源
原生接入	参数传递、池 hooks、指标与身份	工程运行采用
配置修复 r1	补设备配置、显式拒绝缺失配置	先有失败，再有 48 通过
spawn 检查 v2	进度、等待和失败保存	工具采用，非算法升级
本次公开整理	覆盖层、白名单结果、文档与 PDF	不是新 GPU 验收

模型与数据没有虚构版本

没有项目训练权重或微调适配器，也没有训练数据集。0.5B 和 7B 是两种用途，不是模型升级成绩。工作负载 manifest 是固化推理输入，工具层是录制文本。

个人工作边界

上游提供引擎、原生分配和引用/哈希所有权。新增工作是策略生命周期、原生接入、指标、差分测试、固定工作负载及证据工程。代码和文档有 AI 辅助，个人应亲自审阅和解释，不声称从零独立编写整个引擎。

没有创建或合并上游 PR；不声明最新版兼容或完整 ARC。

09 / 演示、复现与限制

无 GPU 最小检查（项目根目录）

```
python -S -B tools/check_release.py
python -S -B tests/test_release_tools.py
```

固定官方基线 + 覆盖层 -> build/vllm-0.8.3。run_checks.py 执行标准库/抽取检查；新输出名拒绝覆盖。原生服务还需已有同版本 Linux 环境、扩展和缓存模型，详见 docs/REPRODUCIBILITY.md。

10 分钟展示

问题 1 分钟；生命周期与源码 2 分钟；配置/指标 1.5 分钟；验证分层 1.5 分钟；结果与负对照 2 分钟；限制和归属 2 分钟。默认回放已有证据，不伪装成实时 GPU。

未覆盖能力

新机器完整依赖哈希锁、每次服务绑定全部权重 SHA、云端 CI 实际运行、上游全套、多 GPU、生产 HA、全部竞态和 GPU KV 数值。0.5B 历史 revision 不完整；7B 有固定 revision 但权重身份链仍有缺口。

来源与进一步阅读

仓库：github.com/lingjiekong04/agentcache-vllm
vLLM 固定上游：github.com/vllm-project/vllm/tree/v0.8.3
APC：docs.vllm.ai/en/v0.8.3/features/automatic_prefix_caching.html
模型：huggingface.co/Qwen/Qwen2.5-7B-Instruct
公开结果与来源：evidence/、SOURCE_MAP.json、PUBLIC_MANIFEST.json

许可：根 LICENSE 为 Apache-2.0；保留上游来源和 SPDX。模型/依赖另行核对。本次不发布原始私有日志、模型、CUDA 扩展或旧 Git bundle。